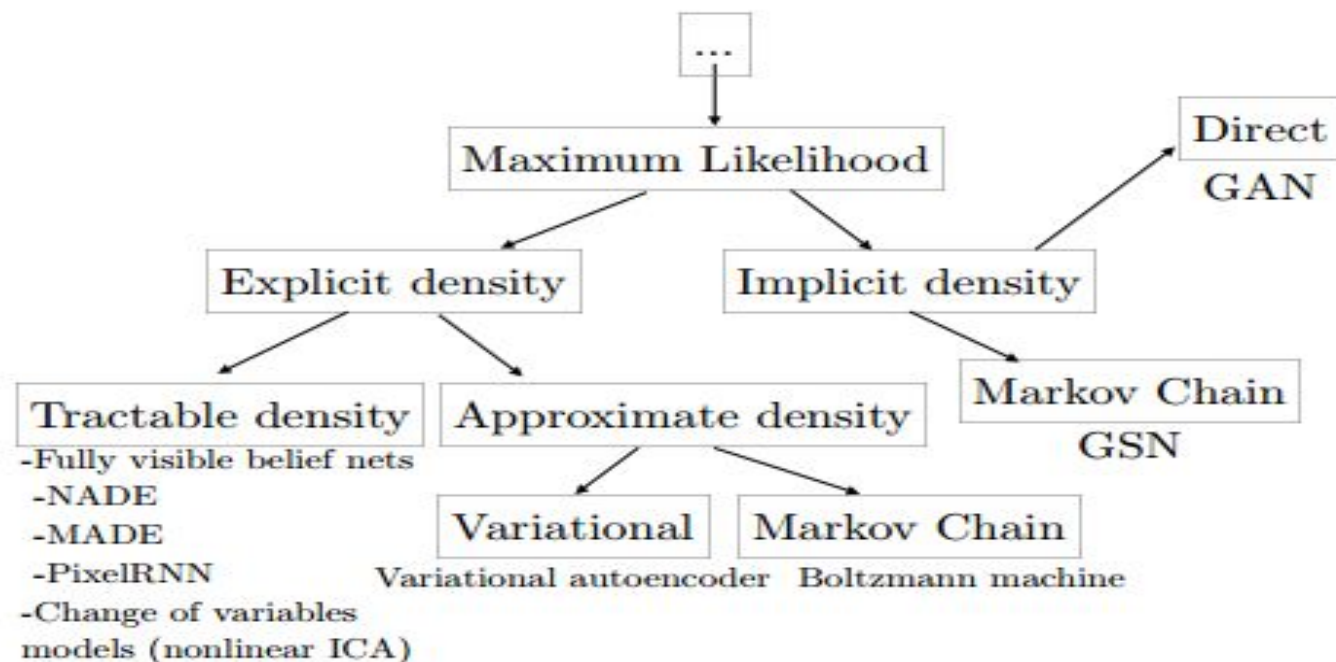

Deep Learning através das abstrações

— Variational Autoencoders (VAEs) —


Generative Models



Ideia Geral


- Um autoencoder para geração
- O problema é que em geral os espaços latentes não são bem comportados
 - Credit Card Fraud
- Resolvemos isso parametrizando ele
 - Isso força seus espaços latentes a serem contínuos
 - Comumente forçamos que ele seja uma normal
 - Média + covariância diagonal

Ideia Geral




Truque da Reparametrização

- Não é possível calcular o gradiente da operação de sample!
- Podemos fazer uma simples modificação da rede para resolver isso



Original



Reparametrized

Perda

- Efetivamente temos duas partes
 - A primeira é o erro de reconstrução (comum a todos os autoencoders)
 - Uma divergência de Kullback-leibler que tenta forçar nosso espaço latente a ser uma normal multidimensional com as dimensões sem correlação

□-VAEs

- Apesar da KL na nossa perda já gerar algum nível de independência no vetor latente, ele compete com o termo de reconstrução
- Podemos aumentar a sua importância com pesos
- Agora temos maior interpretabilidade de cada coordenada do espaço latente

VAEs vs GANs

- VAEs geram imagens mais blurry que GANs
- VAEs tem melhor likelihood que GANs
- VAEs tem espaços latentes mais interpretáveis
- VAEs conseguem gerar compressão
 - Mais usados em World Models
- É conjecturado que GANs podem não aprender algumas modas da distribuição, enquanto VAEs podem explorar regiões que não fazem real sentido

Resources

- [ArXiv Insight](#)
- [Intuitively Understanding VAEs](#)
- [From Autoencoder to Beta-VAE](#)
- [Implementação com Keras](#)
- [Generative Models CS231n](#)
- [Tutorial on VAEs](#)